

به نام خدا



درس یادگیری ماشین
نیم سال دوم ۰۳-۰۴
استاد: ربیعی - دهقانان

دانشکده مهندسی کامپیوتر

زمان آزمون: ۲۰ دقیقه

آزمونک چهارم - ۱۴۰۴/۰۲/۲۱

۱. (۵۰ نمره) فرض کنید شش نقطه‌ی آموزشی (در جدول ۱) برای یک مسئله‌ی دسته‌بندی در اختیار دارید که شامل دو ویژگی دودویی X_1 و X_2 ، و سه کلاس $Y \in \{1, 2, 3\}$ است. ما از قرار است از درخت تصمیم استفاده کنیم.

X_1	X_2	Y
1	1	1
1	1	1
1	1	2
1	0	3
0	0	2
0	0	3

جدول ۱: داده‌های آموزشی

(آ) مقدار کسب اطلاعات (Information-Gain) را برای هر دو ویژگی X_1 و X_2 محاسبه کنید. می‌توانید از تقریب $\log_2 3 \approx \frac{19}{12}$ استفاده کنید.

حل

فرمول کلی بهره اطلاعات:

$$IG(X) = H(Y) - H(Y | X)$$

$$H(X) = - \sum_x P(X = x) \log_2 P(X = x)$$

$$H(Y | X) = \sum_x P(X = x) \sum_y P(Y = y | X = x) \log_2 P(Y = y | X = x)$$

برای محاسبه بهره اطلاعات هر تقسیم ابتدا آنروپی $H(Y)$ را محاسبه می‌کنیم:

$$H(Y) = - \sum_{y_i=1}^{n=3} P(Y = y_i) \log_2 P(Y = y_i)$$

$$= - \sum_{y_i=1}^{n=3} \frac{1}{3} \log_2 \frac{1}{3} = \log_2 3 \approx \frac{19}{12}$$

و برای تقسیم‌بندی X_1 ، آنروپی شرطی آن به صورت زیر محاسبه می‌شود:

$$\begin{aligned}
H(Y | X_1) &= -P(X_1 = 0) \sum_{y_i=1}^{n=3} P(Y = y_i | X_1 = 0) \log_2 P(Y = y_i | X_1 = 0) \\
&\quad - P(X_1 = 1) \sum_{y_i=1}^{n=3} P(Y = y_i | X_1 = 1) \log_2 P(Y = y_i | X_1 = 1) \\
&= - \left[\frac{2}{6} \left(\frac{0}{2} \log_2 \frac{0}{2} + \frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{2} \log_2 \frac{1}{2} \right) \right. \\
&\quad \left. + \frac{4}{6} \left(\frac{2}{4} \log_2 \frac{2}{4} + \frac{1}{4} \log_2 \frac{1}{4} + \frac{1}{4} \log_2 \frac{1}{4} \right) \right] \\
&= - \left(-\frac{2}{6} - 1 \right) = \frac{4}{3}
\end{aligned}$$

به طور مشابه برای تقسیم بندی X_2 آنتروپی شرطی را محاسبه می کنیم:

$$\begin{aligned}
H(Y | X_2) &= -P(X_2 = 0) \sum_{y_i=1}^{n=3} P(Y = y_i | X_2 = 0) \log_2 P(Y = y_i | X_2 = 0) \\
&\quad - P(X_2 = 1) \sum_{y_i=1}^{n=3} P(Y = y_i | X_2 = 1) \log_2 P(Y = y_i | X_2 = 1) \\
&= - \left[\frac{3}{6} \left(\frac{0}{3} \log_2 \frac{0}{3} + \frac{1}{3} \log_2 \frac{1}{3} + \frac{2}{3} \log_2 \frac{2}{3} \right) \right. \\
&\quad \left. + \frac{3}{6} \left(\frac{2}{3} \log_2 \frac{2}{3} + \frac{1}{3} \log_2 \frac{1}{3} + \frac{0}{3} \log_2 \frac{0}{3} \right) \right] \\
&\approx - \left(\frac{2}{3} - \frac{19}{12} \right) \\
&= \frac{11}{12}
\end{aligned}$$

در نتیجه، بهره اطلاعات (Information-Gain) برای هر تقسیم به صورت زیر خواهد بود:

$$IG(X_1) = H(Y) - H(Y | X_1) \approx \frac{19}{12} - \frac{4}{3} = \frac{19}{12} - \frac{16}{12} = \frac{1}{4}$$

$$IG(X_2) = H(Y) - H(Y | X_2) \approx \frac{19}{12} - \frac{11}{12} = \frac{8}{12} = \frac{2}{3}$$

(ب) ابتدا بهتر است داده ها را براساس کدام ویژگی تفکیک کنیم؟

حل

چون مقدار information-gain ویژگی X_2 بیشتر است پس بهتر است از آن برای تفکیک استفاده کنیم.

۲. (۵۰ نمره) به یاد بیاورید که مسئله اولیه‌ی SVM با حاشیه‌ی نرم به صورت زیر است:

$$\begin{aligned} \min \quad & \frac{1}{2} w^T w + C \sum_{i=1}^n \xi_i, \\ \text{s.t.} \quad & \xi_i \geq 0, \quad \forall i \in \{1, \dots, n\}, \\ & (w^T x_i + b) y_i \geq 1 - \xi_i, \quad \forall i \in \{1, \dots, n\}. \end{aligned}$$

برای به دست آوردن SVM با کرنل، دوگان این مسئله گرفته می‌شود و سپس $x_i^T x_j$ با $k(x_i, x_j)$ جایگزین می‌شود، که $k(\cdot, \cdot)$ تابع کرنل است.

شکل ۱ مرزهای تصمیم‌گیری SVM را با کرنل‌ها و/یا ضرایب جریمه‌ی متفاوت نشان می‌دهد. در این شکل، دو دسته داده‌ی آموزشی با برچسب‌های $y_i \in \{-1, 1\}$ داریم که با دایره و مربع مشخص شده‌اند. دایره‌ها و مربع‌های توپر، بردارهای پشتیبان (Support-Vectors) هستند. هر نمودار را با یکی از بهینه‌سازی‌های زیر مطابقت دهید (به طور خیلی مختصر توضیح دهید).

آ) یک SVM خطی با حاشیه‌ی نرم و $C = 0.1$


ب) یک SVM خطی با حاشیه‌ی نرم و $C = 10$

ج) یک SVM با حاشیه‌ی سخت و کرنل $K(u, v) = u^T v + (u^T v)^2$

د) یک SVM با حاشیه‌ی سخت و کرنل $K(u, v) = \exp(-\frac{1}{4}\|u - v\|^2)$

ه) یک SVM با حاشیه‌ی سخت و کرنل $K(u, v) = \exp(-4\|u - v\|^2)$

و) هیچ‌کدام از موارد بالا



شکل ۱:

حل

پاسخ‌ها:

(الف): ۴، (ب): ۳، (ج): ۵، (د): ۱، (ه): ۶، (و): ۲

دلیل:

(الف) مرز تصمیم SVM خطی است. در مقایسه با شکل ۳ (که مربوط به (ب) است)، خط به‌طور دقیق دو کلاس را جدا نمی‌کند، که این حالت مربوط به زمانی است که مقدار C کوچک باشد و خطاهای بیشتری مجاز باشند.

(ب) مرز تصمیم SVM خطی است. در مقایسه با شکل ۴ (که مربوط به (الف) است)، خط دو کلاس را به‌طور دقیق جدا می‌کند، که این حالت نشان‌دهنده مقدار بزرگ C است.

(ج) تابع تصمیم کرنل درجه دوم به صورت زیر تعریف می‌شود: $f(x) = \sum_i \alpha_i (x_i \cdot x + (x_i \cdot x)^2) + b$ در نتیجه، مرز تصمیم برابر است با $f(x) = 0$. از آنجا که $f(x)$ تابعی از مرتبه دوم نسبت به x است، منحنی می‌تواند بیضوی یا هایپربولیک باشد. شکل ۵ یک منحنی هایپربولیک را نشان می‌دهد.

(د) می‌توان تابع تصمیم را به صورت زیر نوشت:

$f(x) = \sum_i \alpha_i \exp(-\gamma \|x_i - x\|^2) + b$ اگر γ بزرگ باشد، مقدار کرنل حتی با وجود فاصله کم بین x_i و x بسیار کوچک می‌شود. این موضوع باعث می‌شود که طبقه‌بندی سخت و تعداد بردارهای پشتیبان کم باشد. اگر شکل ۱ مربوط به حالتی با $\gamma = 4$ (بزرگ) باشد، در آن صورت طبقه‌بندی نقاط دایره‌ای در وسط دشوار خواهد بود. بنابراین، شکل ۱ مربوط به $\gamma = 4$ است.

(ه) با استدلال مشابه، می‌توان نتیجه گرفت که اگر γ کوچک باشد (مثلاً $\gamma = \frac{1}{4}$)، بردارهای پشتیبان بیشتری وجود خواهند داشت.