

به نام خدا



درس یادگیری ماشین
نیمسال دوم ۰۳-۰۴
استاد: ربیعی - دهقانیان

دانشکده مهندسی کامپیوتر

زمان آزمون: ۴۰ دقیقه

آزمونک پنجم - ۱۴۰۴/۳/۱۱


۱. (۲۵ نمره) فرض کنید ماتریس داده زیر را داریم که نمایانگر چهار نقطه نمونه X در \mathbb{R}^2 است:

$$X = \begin{pmatrix} 4 & 1 \\ 2 & 3 \\ 5 & 4 \\ 1 & 2 \end{pmatrix}$$

ما می‌خواهیم داده‌ها را تنها در یک بعد نمایش دهیم، بنابراین از روش تحلیل مولفه‌های اصلی (PCA) استفاده می‌کنیم.
(الف) جهت‌های مؤلفه اصلی با طول واحد (unit-length principal component directions) کنید و مشخص نمایید که اگر فقط یک مؤلفه اصلی درخواست شود، الگوریتم PCA کدام جهت را انتخاب می‌کند.
پاسخ خود را به صورت دقیق و بدون تقریب بیان کنید (نیاز به نماد $\sqrt{\cdot}$ دارد). مراحل و محاسبات خود را نشان دهید.

(ب) نمودار زیر نقاط نمونه را از X نشان می‌دهد. می‌خواهیم نمایش یک بعدی از داده‌ها داشته باشیم. بنابراین:

۱. جهت مؤلفه اصلی انتخاب شده را به صورت یک خط بر روی نمودار رسم کنید.
۲. تصویر (پروجکشن) هر یک از چهار نقطه نمونه را روی این جهت محاسبه و رسم کنید.
۳. هر نقطه پروجکت شده را با مقدار مختصات آن روی مؤلفه اصلی برچسب‌گذاری کنید (مبدأ مختصات بر روی خط مؤلفه اصلی برابر صفر در نظر گرفته شود). مقادیر مختصات مؤلفه‌ها را به طور دقیق و بدون گرد کردن بیان کنید.



پاسخ:

(الف) برای محاسبه جهت‌های مؤلفه اصلی، مراحل زیر طی می‌شود:

۱. مرکزی کردن داده‌ها

ماتریس داده اولیه:

$$X = \begin{pmatrix} 4 & 1 \\ 2 & 3 \\ 5 & 4 \\ 1 & 2 \end{pmatrix}$$

میانگین هر ستون:

$$\mu_1 = \frac{4+2+5+1}{4} = 3, \quad \mu_2 = \frac{1+3+4+2}{4} = 2.5$$

بنابراین، بردار میانگین:

$$\mu = \begin{pmatrix} 3 \\ 2.5 \end{pmatrix}$$

داده‌های مرکزی شده ($X_{\text{centered}} = X - \mu$)

$$X_{\text{centered}} = \begin{pmatrix} 1 & -1.5 \\ -1 & 0.5 \\ 2 & 1.5 \\ -2 & -0.5 \end{pmatrix}$$

۲. محاسبه ماتریس کوواریانس

$$X_{\text{centered}}^T X_{\text{centered}} = \begin{pmatrix} 10 & 2 \\ 2 & 5 \end{pmatrix}, \quad C = \frac{1}{3} \begin{pmatrix} 10 & 2 \\ 2 & 5 \end{pmatrix} = \begin{pmatrix} \frac{10}{3} & \frac{2}{3} \\ \frac{2}{3} & \frac{5}{3} \end{pmatrix}$$

۳. محاسبه مقادیر ویژه و بردارهای ویژه

حل معادله مشخصه:

$$\det(C - \lambda I) = \lambda^2 - 5\lambda + \frac{46}{9} = 0 \Rightarrow 9\lambda^2 - 45\lambda + 46 = 0$$

دیسکریمینانت:

$$\Delta = 45^2 - 4 \cdot 9 \cdot 46 = 369 \Rightarrow \sqrt{369} = 3\sqrt{41}$$

ریشه‌ها:

$$\lambda_{1,2} = \frac{15 \pm \sqrt{41}}{6}$$

بردار ویژه متناظر با λ_1 :

$$\mathbf{v}_1 = \begin{pmatrix} 4 \\ \sqrt{41} - 5 \end{pmatrix}, \quad \|\mathbf{v}_1\| = \sqrt{82 - 10\sqrt{41}}, \quad \mathbf{u}_1 = \frac{1}{\sqrt{82 - 10\sqrt{41}}} \begin{pmatrix} 4 \\ \sqrt{41} - 5 \end{pmatrix}$$

بردار متعامد (برای λ_2):

$$\mathbf{v}_2 = \begin{pmatrix} 5 - \sqrt{41} \\ 4 \end{pmatrix}, \quad \|\mathbf{v}_2\| = \sqrt{82 - 10\sqrt{41}}, \quad \mathbf{u}_2 = \frac{1}{\sqrt{82 - 10\sqrt{41}}} \begin{pmatrix} 5 - \sqrt{41} \\ 4 \end{pmatrix}$$

(ب) ۱. رسم جهت مؤلفه اصلی اول

جهت مؤلفه اصلی اول به صورت خطی از نقطه میانگین عبور می‌کند:

$$y - 2.5 = \frac{\sqrt{41} - 5}{4}(x - 3)$$

۲. محاسبه تصاویر نقاط

نقاط مرکزی شده:

$$\mathbf{x}_1 - \mu = \begin{pmatrix} 1 \\ -1.5 \end{pmatrix}$$

$$\mathbf{x}_2 - \mu = \begin{pmatrix} -1 \\ 0.5 \end{pmatrix}$$

$$\mathbf{x}_3 - \mu = \begin{pmatrix} 2 \\ 1.5 \end{pmatrix}$$

$$\mathbf{x}_4 - \mu = \begin{pmatrix} -2 \\ -0.5 \end{pmatrix}$$

محاسبه ضرب داخلی با \mathbf{u}_1 :

$$\mathbf{x}_1 : \frac{1.5(7 - \sqrt{41})}{\sqrt{82 - 10\sqrt{41}}}$$

$$\mathbf{x}_2 : \frac{0.5(-13 + \sqrt{41})}{\sqrt{82 - 10\sqrt{41}}}$$

$$\mathbf{x}_3 : \frac{0.5(1 + 3\sqrt{41})}{\sqrt{82 - 10\sqrt{41}}}$$

$$\mathbf{x}_4 : \frac{0.5(-11 - \sqrt{41})}{\sqrt{82 - 10\sqrt{41}}}$$

۳. مختصات نقاط تصویرشده (بدون نرمال‌سازی)

نقطه	مختصات روی مؤلفه اصلی
$(4, 1)$	$\frac{7 - \sqrt{41}}{4}$
$(2, 3)$	$\frac{-1 + \sqrt{41}}{4}$
$(5, 4)$	$\frac{13 + \sqrt{41}}{4}$
$(1, 2)$	$\frac{-11 - \sqrt{41}}{4}$

۲. (۳۵ نمره) فرض کنید یک مسئله دسته‌بندی متون داریم، به‌طوری که یک سند X را می‌توان به صورت بردار با اینتری ویژگی‌های کلمات نمایش داد. به بیان دقیق‌تر:

$$X = [X_1, X_2, X_3, \dots, X_m]$$

که

$$X_j = \begin{cases} 1 & \text{اگر کلمه } j \text{ در سند } X \text{ حضور دارد} \\ 0 & \text{در غیر این صورت} \end{cases}$$

با استفاده از الگوریتم AdaBoost و یک یادگیرنده ضعیف ساده تعریف شده به صورت زیر، می‌خواهیم سندها را به یکی از دو کلاس $\{-1, +1\}$ دسته‌بندی کنیم:

$$h(X; \theta) = yX_j,$$

که $(j, y) = \theta$ مشخصه "کلمه انتخاب شده" و "برچسب کلاس" برای آن است. دقت کنید که $\{-1, +1\} \in y$ است. به طور شهودی، برای هر کلمه دو یادگیرنده ضعیف داریم:

- پیش‌بینی sports اگر سند شامل کلمه football باشد.
- پیش‌بینی non-sports اگر سند شامل کلمه football باشد.

(الف) تعداد کل یادگیرنده‌های ضعیف چند عدد است؟
پاسخ: دو یادگیرنده ضعیف برای هر کلمه، یعنی $2m$ یادگیرنده ضعیف.

(ب) این الگوریتم افزایشی را می‌توان برای انتخاب ویژگی‌ها نیز به کار برد. ویژگی‌ها را به ترتیبی که الگوریتم شناسایی می‌کند، انتخاب می‌کنیم.

۱. آیا ممکن است الگوریتم، یک یادگیرنده ضعیف را بیش از یکبار انتخاب کند؟ توضیح دهید.
پاسخ: الگوریتم بوستینگ هر ضریب جدید α را با فرض اینکه تمام ضرایب قبلی ثابت باقی می‌مانند بهینه می‌کند. بنابراین، این الگوریتم این ضرایب را به صورت مشترک بهینه نمی‌کند. تنها راه برای اصلاح آرا اختصاص یافته به یک یادگیرنده ضعیف در مراحل بعدی، افزودن دوباره همان یادگیرنده ضعیف است. از آنجا که در اینجا فقط مجموعه‌ای گسته از یادگیرنده‌های ضعیف داریم، صحبت از انتخاب دوباره دقیقاً همان یادگیرنده ضعیف نیز منطقی به نظر می‌رسد.

۲. اگر ویژگی‌ها را بر اساس اطلاعات متقابل ($Y; z$) مرتب کنیم، آیا این ترتیب می‌تواند بهتر و آگاهانه‌تر از ترتیب به دست آمده توسط AdaBoost باشد؟ توضیح دهید.

پاسخ: الگوریتم بوستینگ ترکیبی خطی از طبقه‌بندی‌های ضعیف (که در اینجا ویژگی‌ها هستند) ایجاد می‌کند. بنابراین، الگوریتم هر طبقه‌بند ضعیف جدید (ویژگی) را نسبت به پیش‌بینی خطی که بر اساس ویژگی‌های از پیش گنجانده شده انجام شده، ارزیابی می‌کند. معیار اطلاعات متقابل هر ویژگی را به صورت جداگانه بررسی می‌کند و به همین دلیل نمی‌تواند تشخیص دهد که چگونه تعامل چندین ویژگی ممکن است به بیهود پیش‌بینی خطی کمک کند.

۳. (۴۰ نمره) درستی یا نادرستی گزاره‌های زیر را با ذکر دلیل مشخص کنید:

(الف) الگوریتم k -NN یک روش غیرپارامتریک است که در مرحله پیش‌بینی از تمام داده‌های آموزشی به طور مستقیم استفاده می‌کند.

پاسخ: درست. الگوریتم NNk -یک روش غیرپارامتریک است، یعنی نیازی به فرض توزیع خاصی برای داده‌ها ندارد. این الگوریتم در زمان پیش‌بینی، مستقیماً از داده‌های آموزشی استفاده می‌کند و k همسایه نزدیک را پیدا می‌کند. به جای ساختن یک مدل کلی، تصمیم‌گیری بر اساس نزدیکی داده‌ها انجام می‌شود.

(ب) در روش «رگرسیون خطی وزن دار محلی» (Locally Weighted Linear Regression)، به دلیل وزن دهنی محلی، مدل قادر است خارج از ناحیه نمونه‌های آموزشی به درستی تعمیم یابد.

پاسخ: نادرست. در رگرسیون خطی وزن دار محلی، برای هر پیش‌بینی یک مدل خطی با وزن دهی به داده‌های نزدیک ساخته می‌شود. این روش در محدوده داده‌های آموزشی دقیق است، اما خارج از آن تعمیم ضعیفی دارد. دلیل این است که وزن‌ها با دور شدن از داده‌ها کاهش می‌یابد و پیش‌بینی بی معنی می‌شود.

(ج) در الگوریتم Value Iteration، در صورتی که سیاست به دست آمده برای یک استیت در T مرحله تغییر نکند، سیاست به دست آمده در این T مرحله همان سیاست بهینه خواهد بود. (به طور دقیق‌تر اگر داشته باشیم $\pi_k = \pi_{k+1} = \dots = \pi_{k+T}$ ،

پاسخ: نادرست. MDP ای را در نظر بگیرید که در آن state‌ها، خانه‌های یک نوار با $3 + T$ خانه هستند. همچنین برای این MDP داریم (دقت کنید که سمت راست s_1 ، استیت s_2 قرار گرفته است):

$$S = \{s_1, s_2, \dots, s_{T+1}, s_{T+2}, s_{T+3}\}, \quad A = \{r(\text{move to right}), l(\text{move to left})\}$$

تابع انتقال:

$$T(s_i, D, s_j) = \begin{cases} 1 & D = r \wedge 1 \leq i \leq T + 1 \wedge j = i + 1 \\ 1 & D = l \wedge i = 1 \wedge j = T + 3 \\ 0 & \text{در غیر این صورت} \end{cases}$$

تابع پاداش:

$$R(s_i, D, s_j) = \begin{cases} 10 & D = r \wedge j = i + 1 = T + 2 \\ 1 & D = l \wedge i = 1 \wedge j = T + 3 \\ 0 & \text{در غیر این صورت} \end{cases}$$

$$(\text{start state, final states}) = (s_1, \{s_{T+2}, s_{T+3}\})$$

بهوضوح در این MDP داریم: (برای همه استیت‌های غیرترمینال، سیاست بهینه حرکت به سمت راست است)

$$\forall 1 \leq i \leq T + 1; \quad V^*(s_i) = 10 \Rightarrow \pi^*(s_i) = r$$

حال دقت کنید که در حین اجرای value iteration برای این MDP خواهیم داشت (با $\gamma = 1$):

$$\forall 1 \leq i \leq T + 1; \quad V_0(s_i) = 0$$

$$V_{k+1}(s_i) = \max_a Q(s_i, a) = Q(s_i, r) = \sum_j T(s_i, r, s_j) (R(s_i, r, s_j) + \gamma V_k(s_j))$$

بنابراین می‌توان نوشت:

$$\forall 1 \leq i \leq T + 1; \quad V_k(s_i) = \begin{cases} 10 & k \geq T + 2 - i \\ 1 & i = 1 \wedge 1 \leq k \leq T \\ 0 & \text{در غیر این صورت} \end{cases}$$

بنابراین در T مرحله ابتدایی اجرای value iteration بر روی این MDP، سیاست به دست آمده برای استیت s_1 ، حرکت به سمت چپ می‌باشد (با مقدار value برابر ۱) که با سیاست بهینه برای این استیت (حرکت به سمت راست) یکسان نمی‌باشد. پس این عبارت نادرست است.

(د) الگوریتم Q-learning تنها زمانی مقادیر بهینه (Q-values) را یاد می‌گیرد که کنش‌هایی (actions) که در نهایت انتخاب می‌شوند براساس سیاست (policy) بهینه باشند.

پاسخ: نادرست. تا زمانی که سیاست مورد استفاده به گونه‌ای باشد که همهی حالات را پیدا کند، Q-learning حتی با یک سیاست رندوم نیز کار می‌کند. Q-values در نهایت به مقادیر بهینه همگرا خواهند شد.

(۵) در یک MDP قطعی (یعنی به ازای هر state یک action مشخص به صورت قطعی رخ می‌دهد) الگوریتم Q-learning با استفاده از نرخ یادگیری $\alpha = 1$ در هر بروزرسانی، به طور صحیح مقادیر Q-values را یاد می‌گیرد.
پاسخ: درست. می‌دانیم نرخ یادگیری در این الگوریتم تنها به این علت وجود دارد که، برای بروزرسانی از یک نمونه (sample) استفاده می‌شود که به صورت قطعی نمی‌دانیم MDP به کدام' s' انتقال خواهد یافت، بنابراین برای تخمین آن نیاز به وزن‌دهی داریم. در بروزرسانی Q، برای یک حالت s و اکشن a خواهیم داشت:

$$Q(s, a) = R(s, a, s') + \gamma \max_{a'} Q(s', a')$$

که دقیقاً همان رابطه بروزرسانی است که در Q-learning انجام می‌دهیم.

(۶) در یک MDP با حالات محدود و پاداش با باند مشخص و $1 < \gamma$ ، اگر همه پاداش‌ها با عدد ثابت c جمع شوند، سیاست بهینه تغییر نمی‌کند.
پاسخ: درست. افزودن یک مقدار ثابت به تمام پاداش‌ها تأثیری بر روی ترتیب نسبی ارزش‌های حالت‌ها ندارد. (البته اگر فرض می‌کردیم که MDP می‌تواند یک حالت terminal داشته باشد، گزاره ممکن بود نادرست شود).
پس به پاسخ‌هایی که برای این حالت مثال نقض آورده‌اند نیز نمره داده شود.)